Slovenská technická univerzita
Fakulta informatiky a informačných technológií
Ilkovičova 2, 842 19 Bratislava 4

Patrik Sčensný

Architektúra počítačových systémov
Semestrálne zadanie

Študijný program: Internetové technológie

Ročník: 1.
Cvičiaci: Ing. Dušan Bernát
Ak. rok: 2017/2018

Obsah

Zadanie

Vytvorte spätný prekladač (disassembler) pre zvolenú architektúru.

Úvod

Spätný prekladač, už iba disassembler, som si vybral pre architektúru MIPS. Výsledky som porovnával s utilitou objdump.

Analýza

V tejto časti sa budem venovať softvérovej a architektickej analýze na splnenie zadania.

Hardvér

Zadanie bude implementované a testované na notebooku ACER Aspire V3-571g s procesorom i5-2300 8GB RAM.

MIPS architektúra

Je reduced instruction set computer (RISC) architektúra inštrukcií (ISA) vyvinutá spoločnosťou MIPS Technologies (predtým MIPS Computer Systems). Skoré MIPS architektúry boli 32-bitové, 64-bitové verzie boli pridané neskôr. Jedna z vlastností MIPS architektúry je že všetky JSI príkazy sú dlhé 32-bitov.

ELF

(Executable and Linkable Format) bol pôvodne vyvinutý a uverejnený systémovými laboratóriami UNIX (USL) ako súčasť Aplikačného binárneho rozhrania (ABI). Výbor pre štandardy rozhrania nástrojov (TIS) vybral vyvíjajúci sa štandard ELF ako súbor prenosného objektu, ktorý funguje na 32-bitovej technológii Intel Architektúry prostredia pre rôzne operačné systémy. Štandard ELF je určený na zefektívnenie vývoja softvéru tým, že poskytuje vývojárom rozhranie, ktoré sa rozprestiera vo viacerých prevádzkových prostrediach. Malo by to znížiť počet rôznych implementácií rozhrania, čím sa znižuje potreba prepisovania a rekompilácie kódu.

Objdump

je program na zobrazovanie rôznych informácií o ELF súboroch. Napríklad, môže byť použitý ako disassembler na zobrazenie spustiteľného súboru vo forme zostavy. Je súčasťou GNU Binutils pre riadenie spustiteľných súborov a iných binárnych údajov

Disassembler

je počítačový program, ktorý prekladá jazyk stroja do assemblerového jazyka - inverznú operáciu ako assembler. Disassembler sa líši od dekompilátora, ktorý sa zameriava skôr na jazyky na vysokej úrovni než na assembler. Výstup disassemblera, je často formátovaný pre ľudskú čitateľnosť skôr ako vhodnosť pre vstup do assembleru, čo je hlavne nástroj pre reverzné inžinierstvo.

Programovací jazyk

Pri implementácií som rozmýšlal nad použitím jazyka C/C++, ale samotná utilita objdump je implementovaná v C. Preto som sa rozhodol použiť jazyk Python, ktorý je momentálne veľmi rozšírený a populárny.

Návrh riešenia

Zadanie som sa rozhodol realizovať v programovacom jazyku Python. Na prvotné zisťovanie architektúry ELF súboru som použil utility: objdump, hexdump. Z pax-utils som použil dumpelf, ktorý mi najviac pomohol pri zistení vnútornej štruktúry súboru.

Implementácia

Predtým ako môžeme prekladať bajty na inštrukcie musíme zistit kde sa tieto inštrukcie nachádzajú. V ELF súbore sa inštrukcie nachádzajú v .text sekcii. Túto sekciu nájdeme v hlavičkách sekcii, ale musíme zistit, či máme správnu hlavičku.

Musíme zistit mená hlavičiek, tie nájdeme v sekcii, .shstrtab, po jej nájdený nájdeme offset .text sekcie a jej dĺžku.

Zistenie inštrukcie

Inštrukcie v MIPS môžeme rozložiť do 4 kategórií:

- R inštrukcia
  - opcode – 6 bitov(iba 0b000000)
  - source register – 5 bitov
  - target register – 5 bitov
  - destination register – 5 bitov
  - shamt(posunutie) immidiate – 5 bitov
  - funct – 6 bitov
- RI inštrukcia
  - opcode – 6 bitov (iba 0b000001)
  - source register – 5 bitov
  - regimm - 5 bitov
  - constant immidiate – 16 bitov
- J inštrukcia
  - opcode – 6 bitov (iba 0b000010 a 0b000011)
  - address – 26 bitov
- I inštrukcia
  - opcode – 6 bitov (všetky ostatné)
  - source register – 5 bitov
  - target register – 5 bitov

- constant immidiate – 16 bitov

Inštrukcie načítavam so súboru JSON, vybral som ho preto lebo Python ma knižnicu ktorá dokáže narábať s JSON súbormi veľmi jednoducho.

```
for j in range(0, 2):...
byte = instruction[1]           # second byte
for j in range(0, 8):...
byte = instruction[2]           # third byte
for j in range(0, 8):...
byte = instruction[3]           # fourth byte
for j in range(0, 8):...

opcode = int(opcode, 2)
add_A = int(add_A, 2)
PC = i
PC = (PC & int("0xf0000000", 16)) | (add_A << 2)
add_A = (PC if PC < 2 ** 31 else PC - 2 ** 32)

# print("opcode: " + str(opcode) + " add_A: " + str(add_A))

with open("instructions.json", "r") as json_file:
    instructions = json.load(json_file)
    for itterator in instructions["instructions"][2]["J"]:
        if itterator["opcode"] == opcode:
            syntax = "{0:0{1}x}".format(i, 8)
            syntax += " " + "{0:0{1}x}".format(int(instruction[0]), 2) + "{0:0{1}x}".format(
                int(instruction[1]), 2) + "{0:0{1}x}".format(int(instruction[2]), 2) \
                    + "{0:0{1}x}".format(int(instruction[3]), 2)
            syntax += "    " + itterator["syntax"]
            address = "{0:0{1}x}".format(add_A, 8)
            address_label.append(address + "     " + "loc_" + address)
            ...
            syntax = syntax.replace("A", "loc_"+address)
            dissassembled_code.append(syntax)
            break
```

Obr. 1 Ukážka program pre rozklad inštrukcie

Priebeh Programu

Keď program spustíte zadáte 2 súbory jeden pre vstup a druhý kde sa má ukladať výstup. Program najprv zistí či vstupný súbor je vhodný pre jeho inštrukcie, ELF súbor to má zapísané. Následne zistí kde sa nachádzajú section headery a ich veľkosti, všetky sú rovnakej veľkosti. Program prezrie všetky headery, a potenciálne headery pre .text a .shstrtab si uloží. Potom program nájde ten správny .shtrtab header, a vďaka nemu nájde .text header. Potom program nájde začiatok .text a jeho veľkosť. Program načítava 4 bajty naraz a tie pomaly rozkladá na jednotlivé podľa typu inštrukcie. Pri inštrukcii typu branch alebo jump, si program zapamätá na ktorú adresu chcel program skočiť a na konci programu na tú adresu napíše návestie.

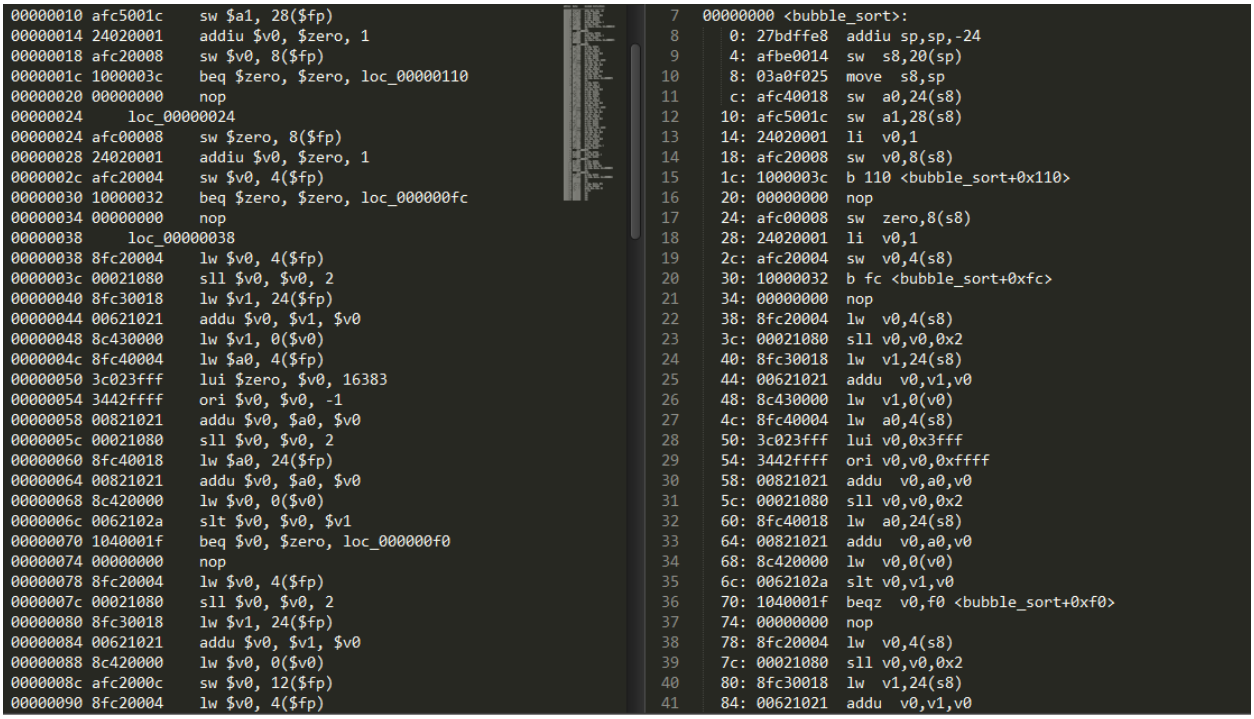

```
00000010 afc5001c    sw $a1, 28($fp)
00000014 24020001    addiu $v0, $zero, 1
00000018 afc20008    sw $v0, 8($fp)
0000001c 1000003c    beq $zero, $zero, loc_00000110
00000020 00000000    nop
00000024     loc_00000024
00000024 afc00008    sw $zero, 8($fp)
00000028 24020001    addiu $v0, $zero, 1
0000002c afc20004    sw $v0, 4($fp)
00000030 10000032    beq $zero, $zero, loc_000000fc
00000034 00000000    nop
00000038     loc_00000038
00000038 8fc20004    lw $v0, 4($fp)
0000003c 00021080    sll $v0, $v0, 2
00000040 8fc30018    lw $v1, 24($fp)
00000044 00621021    addu $v0, $v1, $v0
00000048 8c430000    lw $v1, 0($v0)
0000004c 8fc40004    lw $a0, 4($fp)
00000050 3c023fff    lui $zero, $v0, 16383
00000054 3442ffff    ori $v0, $v0, -1
00000058 00821021    addu $v0, $a0, $v0
0000005c 00021080    sll $v0, $v0, 2
00000060 8fc40018    lw $a0, 24($fp)
00000064 00821021    addu $v0, $a0, $v0
00000068 8c420000    lw $v0, 0($v0)
0000006c 0062102a    slt $v0, $v0, $v1
00000070 1040001f    beq $v0, $zero, loc_000000f0
00000074 00000000    nop
00000078 8fc20004    lw $v0, 4($fp)
0000007c 00021080    sll $v0, $v0, 2
00000080 8fc30018    lw $v1, 24($fp)
00000084 00621021    addu $v0, $v1, $v0
00000088 8c420000    lw $v0, 0($v0)
0000008c afc2000c    sw $v0, 12($fp)
00000090 8fc20004    lw $v0, 4($fp)
```

```
00000000 <bubble_sort>:
   0: 27bdffe8  addiu sp,sp,-24
   4: afbe0014  sw  s8,20(sp)
   8: 03a0f025  move  s8,sp
   c: afc40018  sw  a0,24(s8)
  10: afc5001c  sw  a1,28(s8)
  14: 24020001  li  v0,1
  18: afc20008  sw  v0,8(s8)
  1c: 1000003c  b 110 <bubble_sort+0x110>
  20: 00000000  nop
  24: afc00008  sw  zero,8(s8)
  28: 24020001  li  v0,1
  2c: afc20004  sw  v0,4(s8)
  30: 10000032  b fc <bubble_sort+0xfc>
  34: 00000000  nop
  38: 8fc20004  lw  v0,4(s8)
  3c: 00021080  sll v0,v0,0x2
  40: 8fc30018  lw  v1,24(s8)
  44: 00621021  addu  v0,v1,v0
  48: 8c430000  lw  v1,0(v0)
  4c: 8fc40004  lw  a0,4(s8)
  50: 3c023fff  lui v0,0x3fff
  54: 3442ffff  ori v0,v0,0xffff
  58: 00821021  addu  v0,a0,v0
  5c: 00021080  sll v0,v0,0x2
  60: 8fc40018  lw  a0,24(s8)
  64: 00821021  addu  v0,a0,v0
  68: 8c420000  lw  v0,0(v0)
  6c: 0062102a  slt v0,v1,v0
  70: 1040001f  beqz  v0,f0 <bubble_sort+0xf0>
  74: 00000000  nop
  78: 8fc20004  lw  v0,4(s8)
  7c: 00021080  sll v0,v0,0x2
  80: 8fc30018  lw  v1,24(s8)
  84: 00621021  addu  v0,v1,v0
```

Obr. 3 vľavo disassembler, vpravo objdump

Testovanie

Pri testovaní som porovnával programy ktoré, som často písal v Bakalárskom štúdiu.

Pri testovaní sa podarilo spustit program iba na prostredí Windows, budem sa snažiť opraviť kód aby bolo možné spustit na Unix-like systémoch.

- Quick sort
- Merge sort
- Insert sort
- Bubble sort
- A moje vlastné malé programy

V tabuľke Objdump je čas vykonávania objdump, disassembler je čas vykonávania mojej implemenácie v pythone.

	Bubble		Insert		Merge	
Počet vykonaní merania	Objdump [ms]	Disassembler [ms]	Objdump [ms]	Disassembler [ms]	Objdump [ms]	Disassembler [ms]
1	4	122	5	103	5	104
2	5	117	4	118	5	129
3	5	102	4	108	5	104
4	5	112	4	115	5	114
Priemer	4,75	113,25	4,25	111	5	112,75

	Quick		Snippet 1		Snippet 2	
Počet vykonaní merania	Objdump [ms]	Disassembler [ms]	Objdump [ms]	Disassembler [ms]	Objdump [ms]	Disassembler [ms]
1	5	114	3	111	7	112
2	5	107	4	106	7	109
3	5	100	4	105	8	110
4	5	108	4	105	7	100
Priemer	5	107,25	3,75	106,75	7,25	107,75
	Snippet 3					
Počet vykonaní merania	Objdump [ms]	Disassembler [ms]				
1	3	126				
2	3	105				
3	4	110				
4	4	100				
Priemer	3,5	110,25				

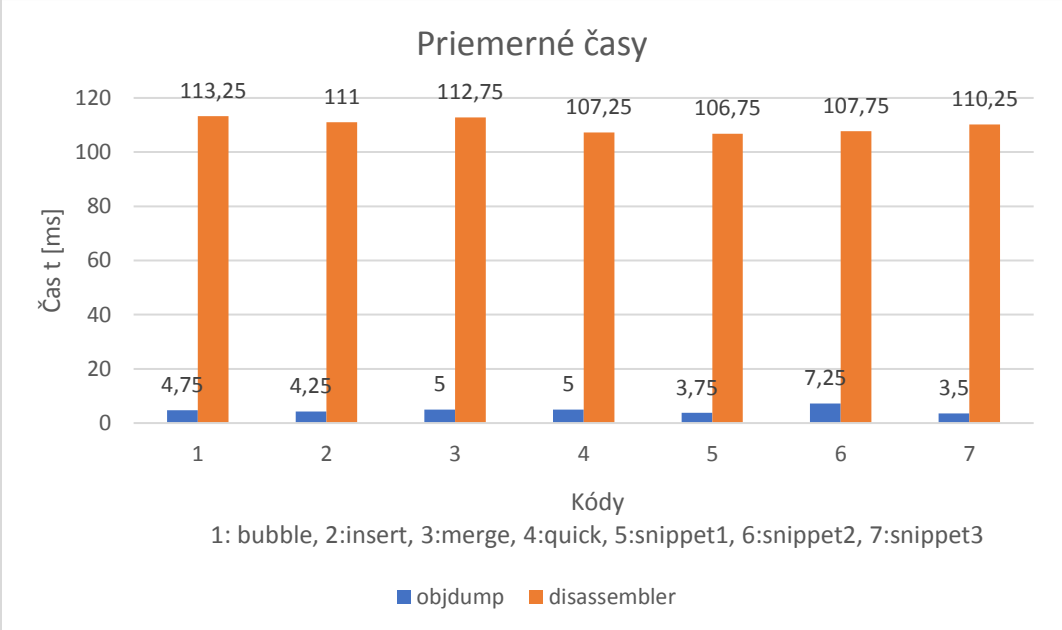

Obr.3 grafické znázornenie priemerných časov jednotlivých kódov

Záver

Pri testovaní som zistil že môj program je pomalší ako utilita objdump, čo sa dalo predpokladať lebo jazyk Python je interpretovaný jazyk oproti C ktoré je kompilovaný. Aj počas písania tohto programu som narazil na problémy ktoré by sa dali v C ľahko riešiť, ale naopak som ma aj problémy ktoré som ľahšie riešil v Pythone ako v C. Môj program je síce pomalý ale spĺňa zadanie, a v porovnaní so zdrojovým kódom objdump, je aj kratší. A vďaka tomu že všetky inštrukcie mám uložené v JSON-e je inštrukčná sada ľahko rošíriteľná bez zmeny zdrojového kódu.

Referencie

www.skyfree.org/linux/references/ELF_Format.pdf

Technická dokumentácia

Program môžeme spusit pomocou príkazu.

“python disassembler.py -I vstupna_binarka -o vystup_programu”

Pri problémoch použite prepínač “-h”